Studi Ablasi RNN, LSTM, dan GRU dibandingkan ANN untuk Prediksi Trafik Seluler Kota Milan

M.Rizki.A.P.
124400046
Muhammad.124400046@student.itera.ac.id
Teknik Telekomunikasi, ITERA

M.Prayoga
124400028
Muhammad.124400028@student.itera.ac.id
Teknik Telekomunikasi, ITERA

Asrofi.T.I.S
124400064
Asrofi.124400064@student.itera.ac.id
Teknik Telekomunikasi, ITERA

***Ringkasan*—Operator seluler memerlukan ramalan trafik per sel untuk perencanaan kapasitas. Kami membandingkan ANN, RNN, LSTM, dan GRU pada prediksi aktivitas internet per jam, satu jam ke depan, di kotak Duomo, Milan (Telecom Italia Big Data Challenge), lalu menguji generalisasinya di Politecnico di (kotak 5772). Studi ablasi mengubah satu faktor setiap kali: panjang jendela, ukuran *hidden*, jumlah lapisan, *learning rate*, kelompok fitur, *batch size*, *optimizer*, dan fungsi *loss*. Pada protokol penuh (300 epoch, 3 seed), RNN mencapai test MAE $229{,}6 \pm 5{,}1$ dan GRU $237{,}2 \pm 9{,}3$, turun 50,9 % dan 49,3 % dari baseline naif terbaik $(467{,}6)$, sedangkan ANN $309{,}9 \pm 5{,}9$; selisih RNN–GRU sebanding dengan variasi antar seed. Sebagian besar ablasi lain dijalankan pada mode cepat (20 epoch) sehingga lebih mencerminkan kecepatan konvergensi: *learning rate* 10^{-2} menurunkan test MAE GRU dari 404 ke 255. Di Politecnico urutan model berubah dan semua model kalah dari baseline naif pada minggu Natal. Anggaran pelatihan dan *learning rate* lebih menentukan daripada pilihan jenis sel rekuren.**

***Index Terms*—prediksi trafik seluler, RNN, LSTM, GRU, studi ablasi**

I. Pendahuluan

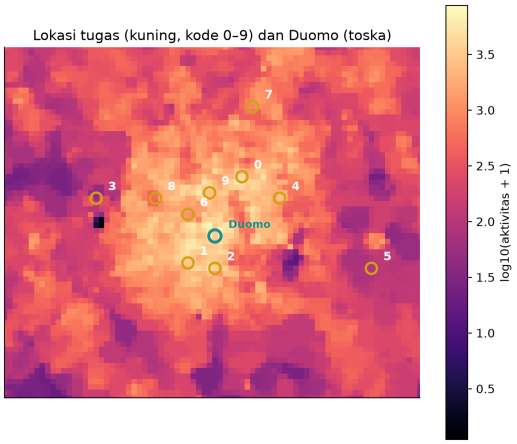
Operator perlu meramal trafik per sel untuk mengatur kapasitas dan energi jaringan, dan trafik per jam memiliki pola harian dan mingguan yang kuat. Model sekuensial seperti RNN, LSTM dan GRU membawa *hidden state* dari jam ke jam, sedangkan ANN hanya melihat jendela yang diratakan. Pertanyaan praktisnya bukan hanya model mana yang menang, tetapi seberapa besar hasil itu bergantung pada pilihan *hyperparameter*. Studi ablasi menjawabnya dengan mengubah satu faktor dari konfigurasi acuan dan mengukur perubahannya.

Kontribusi laporan ini: (i) ablasi lima faktor wajib dan tiga faktor pilihan pada empat model; (ii) perbandingan eksplisit antara protokol pelatihan penuh dan mode cepat, yang menunjukkan bahwa banyak efek *hyperparameter* sebenarnya efek konvergensi; (iii) uji generalisasi ke lokasi lain, termasuk minggu Natal. [6].

II. Data dan Metode

A. Dataset

Kami memakai Telecom Italia Big Data Challenge [7]: aktivitas internet (*net*), panggilan (*call*), dan SMS per kotak, 4 November–29 Desember 2013 (1.344 jam). Analisis utama memakai kotak Duomo (5060). Lokasi kelompok adalah kode 4, Politecnico di Milano, kotak 5772 (Gambar 1).



Gambar 1. Rata-rata aktivitas internet per kotak di Milan. Lingkaran kuning: lokasi tugas (kode 0–9); lingkaran toska: Duomo.

B. Pembagian Data dan Praproses

Pembagian dilakukan menurut waktu: train 11 Nov–8 Des (672 jam), validasi 9–15 Des, test 16–22 Des, dan Natal 23–29 Des; minggu pertama hanya menjadi konteks jendela. Data deret waktu tidak boleh diacak karena sampel bertetangga saling berkorelasi dan pengacakan akan membocorkan masa depan ke data latih. Standarisasi memakai rata-rata dan simpangan baku sebelum minggu validasi, lalu data diubah menjadi jendela geser berisi W jam yang meramal satu jam berikutnya.

C. Model dan Konfigurasi Acuan

ANN meratakan jendela $[W, \text{fitur}]$ lalu melewatkannya pada lapisan tersembunyi ReLU. RNN, LSTM, dan GRU menumpuk lapisan rekuren dan memakai *hidden state* jam terakhir untuk lapisan keluaran. Ukuran *hidden* acuan dipilih agar parameter model rekuren sekitar 5,5 ribu (Tabel I). Seluruh model ditulis dengan PyTorch [8] dan dilatih dengan Adam [9].

D. Protokol Ablasi dan Evaluasi

Setiap kali hanya satu faktor diubah dari acuan. Faktor wajib: A1 panjang jendela $\{6, 12, 24, 48, 168\}$; A2 ukuran *hidden* $\{16, 32, 64, 128\}$; A3 jumlah lapisan $\{1, 2, 3\}$; A4 *learning rate* $\{10^{-4}, 10^{-3}, 10^{-2}\}$; A5 kelompok fitur {net;

Tabel I
KONFIGURASI ACUAN

Hyperparameter	Nilai acuan
Panjang jendela W	24 jam
Horizon	1 jam
Ukuran hidden	ANN 32, RNN 68, LSTM 33, GRU 38
Jumlah lapisan	ANN 2, rekuren 1
Fitur	net, call, sms, jam, hari (7)
Optimizer, *learning rate*	Adam, 10^{-3}
Batch size	64
Early stopping	*patience* 30, maks. 300 epoch

net+call+sms; net+waktu; semua}. Faktor pilihan: B1 *batch size* $\{16, 64, 256\}$, B3 *optimizer* {Adam, AdamW, SGD} [10], dan B4 *loss* {MSE, MAE, Huber}. Hipotesis yang diuji (dari pertanyaan pemandu tugas): jendela panjang membebani ANN (parameter bertambah), lapisan lebih dalam tidak membantu data sekecil ini, SGD kalah dari Adam, dan *loss* MAE menguntungkan metrik MAE.

Metrik adalah MAE, RMSE, dan MAPE pada skala asli; konfigurasi dibandingkan dengan val MAE. Hasil dilaporkan sebagai rata-rata $\pm$ simpangan baku antar seed.

Dua mode pelatihan. Hanya Bagian 0 (acuan) dan A1 dijalankan dengan protokol penuh: 3 seed, maks. 300 epoch, *early stopping* (median 161 epoch). Faktor A2–A5, B, C, dan D dijalankan pada *mode cepat*: maks. 20 epoch, 3 seed untuk A2–A5 dan B1, tetapi hanya 1 seed untuk B3, 2 seed untuk B4 dan D, dan 1 seed untuk konfigurasi terbaik di Bagian C. Perangkat: Ryzen 3 3250U. Total waktu training sesuai log run: 139 menit (mode penuh) ditambah 17 menit (mode cepat), total 156 menit.

III. HASIL

A. Baseline Naif dan Acuan

Baseline naif meramal jam berikutnya dengan nilai jam terakhir, jam yang sama kemarin, atau jam yang sama minggu lalu. Pada minggu test, *minggu lalu* terbaik (MAE 467,6). Pada protokol penuh keempat model mengalahkannya (Tabel II): RNN 50,9 %, GRU 49,3 %, dan ANN 33,7 % lebih rendah. Selisih RNN–GRU (7,6) hanya sedikit di atas simpangan baku RNN (5,1) dan di bawah simpangan baku GRU (9,3), sehingga keduanya sulit dibedakan dengan 3 seed, sedangkan selisih ANN–RNN (80,3) jauh lebih besar daripada variasi seed. Pada mode cepat urutan berubah: ANN (390,8) mengungguli LSTM dan GRU, padahal pada protokol penuh ANN paling lemah. Pada minggu Natal, baseline *nilai terakhir* (431,2) hanya dikalahkan RNN (421,2); baseline *minggu lalu* gagal total (1426,2) karena pola Natal tidak mengulang minggu sebelumnya.

B. Ablasi Wajib

A1: panjang jendela (protokol penuh). Tabel III menunjukkan ANN memburuk seiring W: test MAE naik dari 270,9 ($W = 6$, 2465 parameter) ke 402,0 ($W = 168$, 38 753 parameter), sebab jumlah parameter ANN tumbuh dengan W sementara data latih hanya 672 sampel. Model rekuren hampir tidak sensitif: RNN berkisar 224,5–233,5 dan GRU membaik tipis dari 249,8 ke 234,9, karena parameternya tetap. LSTM paling berisik (273,6–304,4) tanpa tren jelas. Jendela 6 jam sudah cukup untuk horizon 1 jam, sedangkan jendela 168 jam memperlambat training GRU dan LSTM berkali lipat.

A2–A5 (mode cepat). Tabel IV merangkum keempat faktor. *A2 ukuran hidden: hidden* 128 terbaik untuk keempat model (RNN 384 $\rightarrow$ 302, ANN 415 $\rightarrow$ 346), meski kenaikannya tidak selalu monoton; karena nilai *hidden* sama untuk semua model, jumlah parameter LSTM dan GRU tidak setara dengan RNN. *A3 jumlah lapisan:* efeknya berlawanan antar model. RNN membaik dengan kedalaman (315 $\rightarrow$ 280), sedangkan LSTM (399 $\rightarrow$ 483) dan GRU (404 $\rightarrow$ 457) memburuk. *A4 learning rate:* faktor paling berpengaruh. Pada 10^{-4} model tidak sempat konvergen dalam 20 epoch (GRU 1457, LSTM 1712), sedangkan pada 10^{-2} test MAE GRU turun 37 % menjadi 255 dan LSTM 37 % menjadi 252; ANN hampir tidak berubah (387). *A5 fitur:* model rekuren membutuhkan fitur lengkap (RNN: 392 dengan net saja vs. 315 dengan semua fitur). ANN justru lebih baik di minggu Natal tanpa fitur waktu: natal MAE 557 dengan net saja vs. 897 dengan semua fitur.

C. Ablasi Pilihan

Kami memilih B1, B3, dan B4 karena ketiganya memengaruhi seberapa jauh model bergerak dalam anggaran epoch yang tetap. Hipotesis: *batch* kecil lebih baik (lebih banyak pembaruan), SGD lebih lambat daripada Adam, dan *loss* MAE membantu metrik MAE (Tabel V). Ketiganya terbukti. *Batch* 16 menurunkan test MAE GRU ke 298 dan RNN ke 266, sedangkan *batch* 256 memburukkannya (GRU 467, LSTM 538). SGD paling lemah (LSTM 647), sementara Adam dan AdamW praktis identik. *Loss* MAE memperbaiki ANN (390 $\rightarrow$ 340) dan RNN (302 $\rightarrow$ 276), sedangkan Huber sebanding dengan MSE. Karena B3 hanya 1 seed dan B4 hanya 2 seed, kesimpulan B3 bersifat indikatif.

D. Konfigurasi Terbaik

Tabel VI membandingkan konfigurasi hasil penggabungan nilai terpilih (satu seed) dengan acuan mode cepat. Hanya RNN yang membaik pada val MAE (359 $\rightarrow$ 325) dan test MAE (315 $\rightarrow$ 249, turun 21 %; natal 488). Untuk ANN, LSTM, dan GRU, val MAE gabungan justru lebih buruk daripada acuan; test MAE ANN nyaris tidak berubah, sedangkan LSTM dan GRU memburuk, sehingga faktor yang baik secara terpisah tidak otomatis baik bersama (interaksi antar faktor).

E. Uji Generalisasi

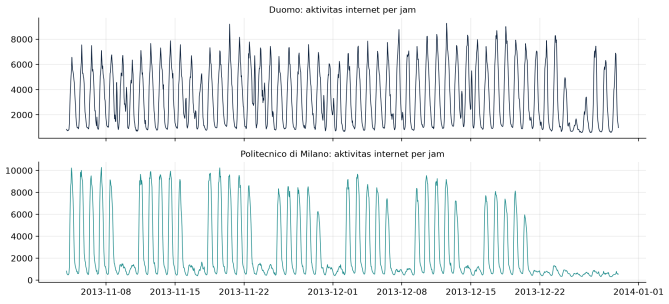
Di Politecnico di Milano (mode cepat, 2 seed) urutan model berubah: ANN terbaik (348), diikuti RNN (383), LSTM (422), dan GRU (438), berbeda dari Duomo, tempat RNN terbaik (Tabel VII). Hanya ANN dan RNN yang jelas mengalahkan baseline *nilai terakhir* (428). Konfigurasi terbaik Duomo tidak menolong di sini (GRU 550, LSTM 514 pada kolom terbaik, simpangan baku besar) dan tidak identik untuk kedua seed. Pada minggu Natal, semua model gagal: natal MAE 753–1490 dibanding baseline *nilai terakhir* yang hanya 57. Gambar 2

Tabel II
BASELINE NAIF DAN KONFIGURASI ACUAN DI DUOMO (HORIZON 1 JAM). PARAMETER, TEST MAE/RMSE/MAPE (%), DAN NATAL MAE UNTUK PROTOKOL PENUH (3 SEED); KOLOM TERAKHIR: TEST MAE MODE CEPAT.

Model	Param	Test MAE	RMSE	MAPE	Natal MAE	Test (cepat)
Naif: nilai terakhir	–	601	771	18,4	431	–
Naif: kemarin	–	552	871	23,8	921	–
Naif: minggu lalu	–	468	757	19,9	1426	–
ANN	6 497	310 ± 6	446 ± 19	$11{,}3 \pm 0{,}8$	680 ± 52	391 ± 13
RNN	5 305	$\mathbf{230 \pm 5}$	338 ± 18	$8{,}5 \pm 0{,}3$	421 ± 2	315 ± 24
LSTM	5 578	274 ± 25	417 ± 37	$9{,}1 \pm 1{,}0$	586 ± 57	399 ± 15
GRU	5 397	237 ± 9	360 ± 14	$8{,}0 \pm 0{,}7$	468 ± 22	404 ± 7

Tabel III
A1: PENGARUH W TERHADAP TEST MAE (RATA-RATA $\pm$ SIMPANGAN BAKU, 3 SEED, PROTOKOL PENUH). TEBAL: TERBAIK PER MODEL.

W (jam)	Param ANN	ANN	RNN	LSTM	GRU
6	2 465	$\mathbf{271 \pm 14}$	229 ± 5	276 ± 15	250 ± 1
12	3 809	309 ± 12	233 ± 11	303 ± 17	246 ± 14
24	6 497	310 ± 6	230 ± 5	$\mathbf{274 \pm 25}$	237 ± 9
48	11 873	333 ± 20	$\mathbf{225 \pm 12}$	304 ± 27	237 ± 11
168	38 753	402 ± 13	234 ± 5	293 ± 20	$\mathbf{235 \pm 14}$



Gambar 2. Aktivitas internet per jam di Duomo dan Politecnico di Milano. Trafik Politecnico turun tajam pada minggu Natal.

menjelaskan sebabnya: Politecnico adalah kampus yang nyaris kosong saat libur, sehingga rata-rata trafik Natal hanya 0,24 kali minggu test (595 vs. 2442), sedangkan Duomo masih 0,65 kali (2359 vs. 3646).

IV. PEMBAHASAN

Yang paling berpengaruh. Perbedaan terbesar bukan antar jenis model, melainkan antara protokol penuh dan mode cepat: test MAE acuan turun, misalnya, dari 403,8 ke 237,2 untuk GRU dan dari 399,5 ke 273,6 untuk LSTM. Karena itu *learning rate* (A4), *batch size* (B1), dan ukuran *hidden* (A2) berpengaruh besar pada mode cepat: ketiganya menambah besar langkah atau jumlah pembaruan sebelum epoch habis. Kami menduga efek ini akan menyusut bila semua faktor dijalankan sampai konvergen, tetapi dugaan tersebut belum kami uji karena A2–A5 dan B hanya dijalankan pada mode cepat. Sebaliknya, W (A1, protokol penuh) hampir tidak memengaruhi model rekuren, dan Adam vs. AdamW tidak berbeda.

Model vs. seed. Pada protokol penuh, RNN dan GRU sulit dipisahkan (selisih 7,6, setara satu simpangan baku), LSTM lebih berisik, dan hanya ANN yang jelas tertinggal. Pada mode cepat dengan 2–3 seed, urutan model tidak stabil (ANN mengalahkan LSTM dan GRU), jadi urutan di Tabel IV dan V tidak boleh dibaca sebagai peringkat arsitektur. Model rekuren yang lebih ringan (RNN) bahkan bersaing dengan LSTM dan GRU pada data sekecil ini, yang konsisten dengan data latih hanya 672 sampel dan horizon 1 jam.

Generalisasi. Pola trafik lokasi menentukan model mana yang cocok. Politecnico memiliki pola kampus yang tajam dan berubah total saat Natal, sehingga model yang dilatih pada empat minggu normal gagal, sedangkan baseline *nilai terakhir* langsung menyesuaikan diri. Ini menunjukkan perlunya data libur dalam pelatihan atau fitur kalender, bukan sekadar *tuning*.

Keterbatasan. (i) Satu kota dan dua lokasi; (ii) empat minggu data latih dan satu kali pembagian waktu; (iii) ablasi A2–A5, B, C, dan D memakai mode cepat 20 epoch dengan jumlah seed yang tidak seragam (B3: 1, B4 dan D: 2); (iv) di Bagian C kami tidak menggabungkan seluruh pemenang val MAE per faktor (misalnya $lr = 10^{-2}$ untuk model rekuren dan *hidden* 128), dan konfigurasi terbaik di Bagian D tidak identik untuk kedua seed, sehingga Tabel VI dan VII tidak mencerminkan konfigurasi terbaik sesungguhnya. Pengulangan C dan D dengan protokol penuh adalah langkah lanjut yang jelas.

V. KESIMPULAN

Pada protokol penuh di Duomo, RNN (229,6) dan GRU (237,2) mencapai test MAE terendah, 50,9 % dan 49,3 % di bawah baseline naif terbaik (467,6), namun keduanya sulit dibedakan pada 3 seed; ANN (309,9) tertinggal dan memburuk dengan jendela panjang. Dalam mode cepat, *learning rate* dan *batch size* adalah faktor paling berpengaruh (GRU: $404 \rightarrow 255$ dengan *learning rate* 10^{-2}), yang kami tafsirkan terutama sebagai efek konvergensi. Konfigurasi hasil tuning di Duomo tidak berlaku di Politecnico, dan pada minggu Natal baseline naif sederhana mengalahkan semua model di sana.

KONTRIBUSI ANGGOTA

Muhammad Rizki Akbar P.	Melakukan percobaan dan mengelola github.
Muhammad Prayoga	Menyusun laporan dan mencari referensi.
Asrofi T Insani Siregar	Menyusun laporan dan mencari referensi.

Tabel IV
A2–A5: TEST MAE DI DUOMO (RATA-RATA ± SIMPANGAN BAKU, 3 SEED, MODE CEPAT 20 EPOCH). TEBAL: TERBAIK PER MODEL DALAM SATU FAKTOR. NILAI *hidden* SAMA UNTUK SEMUA MODEL.

Nilai	ANN	RNN	LSTM	GRU
A2. Ukuran hidden				
16	415 ± 22	384 ± 37	424 ± 24	438 ± 40
32	391 ± 13	334 ± 10	393 ± 4	387 ± 15
64	352 ± 39	344 ± 28	377 ± 13	387 ± 16
128	$\mathbf{346 \pm 35}$	$\mathbf{302 \pm 11}$	$\mathbf{374 \pm 11}$	$\mathbf{353 \pm 18}$
A3. Jumlah lapisan				
1	387 ± 6	315 ± 24	$\mathbf{399 \pm 15}$	$\mathbf{404 \pm 7}$
2	391 ± 13	295 ± 4	437 ± 15	412 ± 12
3	$\mathbf{371 \pm 6}$	$\mathbf{280 \pm 7}$	483 ± 11	457 ± 18
A4. Learning rate				
10^{-4}	655 ± 167	547 ± 45	1712 ± 60	1457 ± 83
10^{-3}	391 ± 13	315 ± 24	399 ± 15	404 ± 7
10^{-2}	$\mathbf{387 \pm 15}$	$\mathbf{264 \pm 18}$	$\mathbf{252 \pm 7}$	$\mathbf{255 \pm 11}$
A5. Kelompok fitur				
net	$\mathbf{364 \pm 10}$	392 ± 14	447 ± 28	424 ± 17
net+call+sms	407 ± 27	325 ± 9	$\mathbf{384 \pm 22}$	$\mathbf{382 \pm 17}$
net+waktu	394 ± 6	352 ± 20	431 ± 13	431 ± 30
semua	391 ± 13	$\mathbf{315 \pm 24}$	399 ± 15	404 ± 7

Tabel V
B1, B3, B4: TEST MAE DI DUOMO (MODE CEPAT). † SATU SEED, TANPA SIMPANGAN BAKU.

Nilai	ANN	RNN	LSTM	GRU
B1. Batch size				
16	$\mathbf{369 \pm 43}$	$\mathbf{266 \pm 25}$	$\mathbf{324 \pm 10}$	$\mathbf{298 \pm 17}$
64	391 ± 13	315 ± 24	399 ± 15	404 ± 7
256	449 ± 41	424 ± 19	538 ± 60	467 ± 38
B3. Optimizer (1 seed)				
adam	$\mathbf{392}$ †	$\mathbf{342}$ †	$\mathbf{410}$ †	$\mathbf{404}$ †
adamw	392 †	342 †	410 †	404 †
sgd	460 †	395 †	647 †	516 †
B4. Fungsi loss (2 seed)				
mse	390 ± 18	302 ± 5	394 ± 17	404 ± 10
mae	$\mathbf{340 \pm 3}$	$\mathbf{276 \pm 17}$	$\mathbf{366 \pm 12}$	$\mathbf{389 \pm 11}$
huber	384 ± 15	297 ± 4	388 ± 19	398 ± 10

Tabel VI
ACUAN / TERBAIK (MODE CEPAT, DUOMO): VAL, TEST, DAN NATAL MAE. KONFIGURASI TERBAIK MEMAKAI 1 SEED.

Model	Perubahan	Val MAE	Test MAE	Natal MAE
ANN	$lr = 5{\cdot}10^{-4}$, batch 32, AdamW	377 / 388	391 / 387	897 / 888
RNN	batch 32, *loss* MAE	359 / 325	315 / 249	613 / 488
LSTM	*dropout* 0,2, AdamW	450 / 483	400 / 424	878 / 947
GRU	$lr = 5 \cdot 10^{-4}$	476 / 512	404 / 426	803 / 821

PERNYATAAN PENGGUNAAN AI

Alat AI yang dipakai adalah Claude AI yang digunakan untuk memperbaiki kode latex, merapikan bahasa,mencari referensi, dll.

KODE DAN DATA

Kode, notebook beserta output, dan seluruh hasil run tersedia di https://github.com/Frostbite114/Studi-ablasi-RNN-LSTM-GRU-vs-ANN.

Tabel VII
POLITECNICO DI MILANO (KODE 4, KOTAK 5772), MODE CEPAT, 2 SEED: TEST MAE ACUAN, TEST MAE KONFIGURASI TERBAIK DUOMO, DAN NATAL MAE ACUAN.

Model	Test (acuan)	Test (terbaik)	Natal (acuan)
Naif: nilai terakhir	428	–	57
Naif: kemarin	859	–	138
Naif: minggu lalu	504	–	1847
ANN	$\mathbf{348 \pm 7}$	345 ± 12	1490 ± 136
RNN	383 ± 10	368 ± 32	753 ± 99
LSTM	422 ± 5	514 ± 124	1177 ± 53
GRU	438 ± 8	550 ± 165	1020 ± 42

PUSTAKA

[1] G. L. Santos, P. Rosati, T. Lynn, J. Kelner, D. Sadok, and P. T. Endo, "Predicting short-term mobile Internet traffic from Internet activity using recurrent neural networks," *International Journal of Network Management*, vol. 32, no. 3, Art. no. e2191, 2022. doi: 10.1002/nem.2191.

[2] D. Zhang, L. Liu, C. Xie, B. Yang, and Q. Liu, "Citywide cellular traffic prediction based on a hybrid spatiotemporal network," *Algorithms*, vol. 13, no. 1, Art. no. 20, 2020. doi: 10.3390/a13010020.

[3] G. Chen, Y. Guo, Q. Zeng, and Y. Zhang, "A novel cellular network traffic prediction algorithm based on graph convolution neural networks and long short-term memory through extraction of spatial-temporal characteristics," *Processes*, vol. 11, no. 8, Art. no. 2257, 2023. doi: 10.3390/pr11082257.

[4] A. A. Hussien, H. Nashaat, and R. F. Abdel-Kader, "Machine learning techniques for spatiotemporal traffic prediction in 5G cellular networks," *Discover Applied Sciences*, vol. 7, Art. no. 1047, 2025. doi: 10.1007/s42452-025-06746-3.

[5] J. Chung, C. Gulcehre, K. Cho, and Y. Bengio, "Empirical evaluation of gated recurrent neural networks on sequence modeling," arXiv preprint arXiv:1412.3555, 2014.

[6] S. Hochreiter and J. Schmidhuber, "Long Short-Term Memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997. doi: 10.1162/neco.1997.9.8.1735.

[7] G. Barlacchi et al., "A Multi-Source Dataset of Urban Life in the City of Milan and the Province of Trentino," *Scientific Data*, vol. 2, Art. no. 150055, 2015. doi: 10.1038/sdata.2015.55.

[8] A. Paszke et al., "PyTorch: An Imperative Style, High-Performance Deep Learning Library," in *Advances in Neural Information Processing Systems 32*, 2019, pp. 8024–8035.

[9] D. P. Kingma and J. Ba, “Adam: A Method for Stochastic Optimization,” in *International Conference on Learning Representations (ICLR)*, 2015.
[10] I. Loshchilov and F. Hutter, “Decoupled Weight Decay Regularization,” in *International Conference on Learning Representations (ICLR)*, 2019.